

Αυτοματοποιημένη εφαρμογή των ACMG κριτηρίων (PS1, PM5, PP5 και BP6) σε γενετικές παραλλαγές

Σκοπός αυτού του project είναι η δημιουργία ενός pipeline, το οποίο θα αξιολογεί τα στοιχεία που υπάρχουν διαθέσιμα στην ClinVar και θα εφαρμόζει τα ACMG 2015 κριτήρια (PS1, PM5, PP5 και BP6) για τις γενετικές παραλλαγές. Με αυτό τον τρόπο, παρέχεται ένα κανονικοποιημένο (standardized) και βασισμένο σε στοιχεία (evidence-based) πλαίσιο για την ερμηνεία της κλινικής σημασίας των γενετικών παραλλαγών.

Script annotations

Για την επίτευξη αυτού του στόχου χρειάστηκε η δημιουργία μιας βάσης δεδομένων, η οποία θα αποθηκεύει τα δεδομένα που υπάρχουν στη ClinVar σχετικά με την κάθε παραλλαγή και θα έχει τη δυνατότητα να μπορεί να τα επεξεργάζεται και να πραγματοποιεί αναλύσεις. Επίσης, η δημιουργία ενός περιβάλλοντος REST API ήταν επιθυμητή για την άμεση επικοινωνία με τη βάση δεδομένων, αλλά και για να είναι πιο φιλική προς τον χρήστη αυτή η εφαρμογή, καθώς ένας σημαντικό μέρος του κοινού στο οποίο απευθύνεται για χρήση αποτελούν επιστήμονες και κλινικοί, οι οποίοι δεν είναι γνώστες και χρήστες εργαλείων βιοπληροφορικής.

Ο κώδικας βασίστηκε στην Python ως γλώσσα προγραμματισμού και το σύστημα για το χτίσιμο της βάσης δεδομένων βασίστηκε στην PostgreSQL. Το API δημιουργήθηκε με τη χρήση του FastAPI.

Για την ανάπτυξη του κώδικα χρειάζεται η εφαρμογή κάποιων βιβλιοθηκών. Πιο συγκεκριμένα αυτές που χρησιμοποιήθηκαν είναι οι εξής:

1. **pandas:** για τον χειρισμό δεδομένων που βρίσκονται σε μορφή πινάκων. Επιτρέπει τη δημιουργία και τον χειρισμό DataFrames.
2. **psycopg2:** σύνδεση εφαρμογών της Python με PostgreSQL βάσεις δεδομένων. Επιτρέπει την εκτέλεση SQL queries.
3. **os:** επιτρέπει την αλληλεπίδραση με το λειτουργικό σύστημα.
4. **urllib:** επιτρέπει την εισαγωγή και την εργασία με URLs.
5. **typing:** επιτρέπει την προσθήκη type hints (υποδείξεις τύπων) μέσα στον κώδικα.
6. **re:** επιτρέπει τη χρήση κανονικών εκφράσεων (regular expressions).
7. **traceback:** βοηθά στην καλύτερη λειτουργία του προγράμματος με την εμφάνιση λαθών (errors), όπου προκύπτουν.
8. **subprocess:** επιτρέπει να τρέξουμε εξωτερικά προγράμματα ή εντολές μέσα από κώδικα Python.
9. **collections:** για τη χρήση προηγμένων δομών δεδομένων, πιο ισχυρών και αποδοτικών από τις απλές που υπάρχουν ενσωματωμένες (λίστες, λεξικά, πλειάδες).

Ξεκινώντας με τα βασικά στοιχεία του κώδικα της βάσης δεδομένων, αρχικά ορίζονται οι ρυθμίσεις της βάσης, όπως το URL της ClinVar από όπου θα παραληφθεί το αρχείο *variant_summary.txt*¹, το οποίο περιέχει όλα τα διαθέσιμα δεδομένα που υπάρχουν για μία παραλλαγή στη ClinVar. Το αρχείο *variant_summary.txt* είναι μία αναφορά που οριοθετείται από tabs και περιέχει δεδομένα για κάθε παραλλαγή σε κάθε σημείο του γονιδιώματος για το οποίο υπάρχει καταγραφή στην ClinVar. Τα δεδομένα για κάθε παραλλαγή αναφέρονται για κάθε έκδοση του γονιδιώματος αναφοράς, οπότε οι περισσότερες παραλλαγές έχουν αναφορές τόσο για την GRCh37 (hg19), όσο και για την GRCh38 (hg38) έκδοση του γονιδιώματος². Πιο συγκεκριμένα το *variant_summary.txt* περιέχει τις εξής στήλες:

1. **AlleleID:** integer, value as stored in the AlleleID field in ClinVar.
2. **Type:** character, the type of variant represented by the AlleleID.
3. **Name:** character, ClinVar's preferred name for the record with this AlleleID.
4. **GeneID:** integer, GeneID in NCBI's Gene database, reported if there is a single gene, otherwise reported as -1.

¹ https://ftp.ncbi.nlm.nih.gov/pub/clinvar/tab_delimited/variant_summary.txt.gz

² https://ftp.ncbi.nlm.nih.gov/pub/tab_delimited/README

5. **GeneSymbol:** character, comma-separated list of GeneIDs overlapping the variant.
6. **HGNC_ID:** string, of format HGNC: integer, reported if there is a single GeneID. Otherwise reported as '- '.
7. **ClinicalSignificance:** character, semicolon-separated list of aggregate values of germline classification calculated for this variant. Because the aggregate values of germline classification give precedence to records with assertion criteria and evidence, the values in this column may appear to be in conflict with the value reported in ClinSigSimple.
8. **ClinicalSignificanceSimplified:** integer, 0 = no current value of Likely pathogenic; Pathogenic; Likely pathogenic, low penetrance; Pathogenic, low penetrance; Likely risk allele; or Risk allele.
1 = at least one current record submitted with an interpretation of Likely pathogenic; Pathogenic; Likely pathogenic, low penetrance; Pathogenic, low penetrance; Likely risk allele; or Risk allele (independent of whether that record includes assertion criteria and evidence).
-1 = no values for clinical significance at all for this variant or set of variants; used for the “included” variants that are only in ClinVar because they are included in a haplotype or genotype with an interpretation.
NOTE: Now that the aggregate values of clinical significance give precedence to records with assertion criteria and evidence, the values in this column may appear to be in conflict with the value reported in ClinicalSignificance. In other words, if a submission without assertion criteria and evidence interpreted an allele as pathogenic, and those with assertion criteria and evidence interpreted as benign, the ClinicalSignificance would be reported as Benign and ClinSigSimple as 1.
9. **LastEvaluated:** date, the latest “date last evaluated” on submissions with a germline classification for the variant
10. **RS# (dbSNP):** integer, rs# in dbSNP, reported as -1 if missing
11. **Nsc/esv (dbVar):** character, the NSV identifier for the region in dbVar
12. **RCVaccession:** character, list of RCV accessions that report this variant, separated by a pipe.
13. **PhenotypeIDs:** character, list of identifiers for condition(s) this variant was classified for.

If there are more than one RCV in the RCVaccession column, the sets of identifiers per RCV are separated by a pipe. Multiple identifiers for the same condition are separated by a comma.

If an RCV has more than one condition, the set of identifiers for each condition are separated by a semi-colon.

If an RCV has more than 5 conditions, the number of conditions is reported instead all of the identifiers.

14. **PhenotypeList:** character, list of condition name corresponding to PhenotypeIDs. *If there are more than one RCV in the RCVaccession column, the sets of names per RCV are separated by a pipe.*

If an RCV has more than one condition, the set of identifiers for each condition are separated by a semi-colon.

If an RCV has more than 5 conditions, the number of conditions, the number of conditions is reported instead of all the identifiers.

15. **Origin:** character, list of all allelic origins for this variant.

16. **OriginSimple:** character, processed from Origin to make it easier to distinguish between germline and somatic.

17. **Assembly:** character, name of the assembly on which locations are based.

18. **ChromosomeAccession:** Accession and version of the RefSeq sequence defining the position reported in the start and stop columns.

19. **Chromosome:** character, chromosomal location.

20. **Start:** integer, starting location, right-shifted, in pter -> qter orientation.

21. **Stop:** integer, end location, right-shifted, in pter -> qter orientation.

22. **ReferenceAllele:** The reference allele using the right-shifted location in Start and Stop.

23. **AlternateAllele:** The alternate allele using the right-shifted location in Start and Stop.

24. **Cytogenetic:** character, ISCN band.

25. **ReviewStatus:** character, review status for the aggregate germline classification for this variant.³

26. **NumberSubmitters:** integer, number of submitters describing this variant.

³ For the key to the terms, and the stars displayed on ClinVar web pages, see http://www.ncbi.nlm.nih.gov/clinvar/docs/review_status/

27. **Guidelines:** character, ACMG only right now, for the reporting of incidental variation in a Gene enumerates whether the guidelines are from 2013 (ACMG2013, PubMed 23788249) or 2016 (ACMG2016, PubMed 27854360) (NOTE: if ACMG, not specific to the AlleleID but to Gene in which the AlleleID is found).
28. **TestedInGTR:** character, Y/N for Yes/No if there is a test registered as specific to this variant in the NIH Genetic Testing Registry (GTR).
29. **OtherIDs:** character, list of other identifiers or sources of information about this variant
30. **SubmitterCategories:** coded value to indicate whether data were submitted by another resource (1), any other type of source (2), both (3), or none (4).
31. **VariationID:** The identifier ClinVar uses specific to the AlleleID. Not all VariationIDs may be related to the AlleleID are reported in this file.⁴
32. **PositionVCF:** integer, starting location, left-shifted, in pter -> qter orientation.
33. **ReferenceAlleleVCF:** The reference allele using the left-shifted location in vcf_pos.
34. **AlternateAlleleVCF:** The alternate allele using the left-shifted location in vcf_pos.
35. **SomaticClinicalImpact:** character, aggregate value for somatic classification of clinical impact calculated for this variant.
36. **SomaticClinicalImpactLastEvaluated:** date, the latest “date last evaluated” on submissions with a somatic classification of clinical impact for the variant.
37. **ReviewStatusClinicalImpact:** character, review status for the aggregate somatic classification of clinical impact for this variant.⁵
38. **Oncogenicity:** character, aggregate value of oncogenicity classification calculated for this variant.
39. **OncogenicityLastEvaluated:** date, the latest “date last evaluated” on submissions with an oncogenicity classification for this variant.

⁴ For a comprehensive mapping of AlleleID to VariationID, please use ftp://ftp.ncbi.nlm.nih.gov/pub/clinvar/tab_delimited/variation_allele.txt.gz

⁵ For the key to the terms, and the stars displayed on ClinVar web page, see http://www.ncbi.nlm.nih.gov/docs/review_status/

40. **ReviewStatusOncogenicity:** *character, review status for the aggregate oncogenicity classification for this variant.*⁶

Η συνάρτηση `DB_CONFIG()` ορίζει όλες τα απαραίτητα στοιχεία για τη σύνδεση σε μια PostgreSQL βάση δεδομένων. Αυτά περιλαμβάνουν:

1. το όνομα της βάσης (*dbname*),
2. το όνομα χρήστη της βάσης (*user*),
3. τον κωδικό για τη σύνδεση στη βάση (*password*),
4. το όνομα του server ή της τοποθεσίας όπου τρέχει η βάση δεδομένων και είναι δυνατή η πρόσβαση σε αυτή (*host*) και
5. το *port* της PostgreSQL (5432)

Επιπλέον υπάρχουν βοηθητικές συναρτήσεις, οι οποίες βοηθούν στην ανάλυση των δεδομένων και την επεξεργασία τους έτσι ώστε να μπορεί να πραγματοποιηθεί η διαδικασία της εφαρμογής των ACMG κριτηρίων. Σε αυτές περιλαμβάνεται η συνάρτηση `create_tables()`, η οποία δημιουργεί τον βασικό πίνακα της βάσης δεδομένων. Αυτός στη συνέχεια θα γεμίσει τα κατάλληλα πεδία με τα δεδομένα από το *variant_summary.txt*. Ο πίνακας της βάσης δεδομένων περιέχει τις εξής στήλες:

1. **variation_id:** BIGINT PRIMARY KEY, αντιστοιχεί στο VariantID της ClinVar. Είναι μοναδικό για κάθε παραλλαγή.
2. **gene_symbol:** TEXT NOT NULL, ο επίσημος συμβολισμός του γονιδίου με βάση την HGNC ονομασία του.
3. **transcript_id:** TEXT, το όνομα του μεταγράφου με βάση το NCBI. Αναφέρεται στο πλήρες όνομα της παραλλαγής (ξεκινάει με 'NM_').
4. **hgvs_c:** TEXT, ο συμβολισμός της παραλλαγής σε επίπεδο DNA με βάση τον συμβολισμό HGVS. Αναφέρεται στο πλήρες όνομα της παραλλαγής ('c.').
5. **hgvs_p:** TEXT, ο συμβολισμός της παραλλαγής σε επίπεδο πρωτεΐνης με βάση τον συμβολισμό HGVS. Αναφέρεται στο πλήρες όνομα της παραλλαγής, αν υπάρχει ('p.').
6. **molecular_consequence:** TEXT, η συνέπεια που έχει η παραλλαγή του DNA σε μοριακό επίπεδο με βάση το μετάγραφο. Υπολογίζεται με βάση την αλλαγή του DNA που συνέβη. Για παράδειγμα, μία παραλλαγή μπορεί να προκαλεί

⁶ For the key to the terms, and the stars displayed on ClinVar web pages, see http://www.ncbi.nlm.nih.gov/clinvar/docs/review_status/

παρανοηματική μεταλλαγή (missense mutation, αλλαγή του αμινοξικού καταλοίπου), συνώνυμη μεταλλαγή (καμία αλλαγή στο αμινοξικό κατάλοιπο), nonsense μεταλλαγή (αλλαγή σε κωδικόνιο λήξης), αλλαγή αναγνωστικού πλαισίου (frameshift) κ.α.

7. **clinicalsignificance:** TEXT, η κλινική σημασία της παραλλαγής όπως αναφέρεται στην ClinVar.
8. **clinsigsimple:** TEXT, η κλινική σημασία απλοποιημένη και κανονικοποιημένη, για να είναι πιο εύκολο να χρησιμοποιηθεί στις αναλύσεις.
9. **review_status:** TEXT, η κατάσταση αξιολόγησης της παραλλαγής όπως αναφέρεται στη ClinVar.
10. **phenotype_list:** TEXT, λίστα με τους φαινότυπους στους οποίους εμφανίζεται αυτή η παραλλαγή όπως αναφέρεται στη ClinVar.
11. **assembly:** TEXT NOT NULL, η έκδοση του γονιδιώματος πάνω στην οποία βασίζονται τα δεδομένα της παραλλαγής.
12. **chromosome:** TEXT, ο αριθμός του χρωμοσώματος που εντοπίζεται η παραλλαγή.
13. **start_pos:** INTEGER, οι γονιδιωματικές συντεταγμένες από όπου ξεκινάει η παραλλαγή.
14. **end_pos:** INTEGER, οι γονιδιωματικές συντεταγμένες όπου τελειώνει η παραλλαγή.
15. **reference_allele:** TEXT, το φυσιολογικό αλληλόμορφο αναφοράς που υπάρχει σε εκείνη τη θέση.
16. **alternate_allele:** TEXT, το εναλλακτικό αλληλόμορφο αναφοράς, αν υπάρχει, που μπορεί να εντοπίζεται στη συγκεκριμένη θέση σε φυσιολογικό φαινότυπο.
17. **acmg_criteria:** JSONB, εμφανίζει όλα τα ACMG κριτήρια που εφαρμόζονται για τη συγκεκριμένη παραλλαγή.
18. **acmg_from_grouping:** TEXT, εμφανίζει τα ACMG κριτήρια που εφαρμόζονται με τη μέθοδο ομαδοποίησης.
19. **acmg_combined_criteria:** TEXT, εμφανίζει το ACMG κριτήριο που είναι πιο ισχυρό για τη συγκεκριμένη παραλλαγή.
20. **conflicting_interpretations:** JSONB, εμφανίζει αν υπάρχουν αντικρουόμενες ερμηνείες για τη συγκεκριμένη παραλλαγή και ποιες είναι αυτές .
21. **rcvaccession:** TEXT[], τυπώνει όλους τους RCV κωδικούς που αντιστοιχούν στη συγκεκριμένη παραλλαγή, όπως αναφέρονται στην ClinVar.

22. **last_updated:** TIMESTAMP DEFAULT CURRENT_TIMESTAMP, εμφανίζει την τελευταία ενημέρωση των δεδομένων, η οποία ταυτίζεται με την ώρα που πραγματοποιείται η αναζήτηση από τον χρήστη.
23. **last_evaluated:** DATE, η ημερομηνία της τελευταίας αξιολόγησης των δεδομένων.
24. **protein_pos:** BIGINT, η θέση του αμινοξικού καταλοίπου στο οποίο εντοπίζεται η παραλλαγή.

Η συνάρτηση *consequence()* χρησιμοποιεί το *hgvs_p* για να εξάγει τη μοριακή συνέπεια που έχει η παραλλαγή σε επίπεδο πρωτεΐνης (π.χ. missense, nonsense, frameshift κ.λπ.). Η συνάρτηση *consequence_dna()* χρησιμοποιεί το *hgvs_c* για να εξάγει από την αλλαγή στο DNA τον τύπο της μοριακής συνέπειας που έχει η παραλλαγή. Αυτό συμπεριλαμβάνει τις παραλλαγές που δεν έχουν αμινοξική αλλαγή ως αποτέλεσμα (π.χ. 3' UTR, 5' UTR, προσθήκη, έλλειμμα, αντικατάσταση κ.λπ.). Η *variant_consequence()* τυπώνει τα αποτελέσματα της *consequence()* και της *consequence_dna()*, ενώ η *combine_consequence()* εμφανίζει μόνο την πιο επικρατή συνέπεια. Αυτή είναι η μοριακή συνέπεια σε επίπεδο πρωτεΐνης κυρίως.

Για τη χρήση των συναρτήσεων που αφορούν τη μοριακή συνέπεια της παραλλαγής χρειάζονται τα στοιχεία *hgvs_c* και *hgvs_p*. Αυτά εξάγονται από το πλήρες όνομα της παραλλαγής με τη χρήση της συνάρτησης *extract_HGVS()*. Τα *hgvs_c* και *hgvs_p* είναι, επίσης, χρήσιμα και για την εφαρμογή των ACMG κριτηρίων PS1, PP5 και BP6.

Για την εφαρμογή του PM5 κριτηρίου, είναι απαραίτητο να είναι γνωστή η θέση του καταλοίπου. Για αυτό τον λόγο εφαρμόζεται η συνάρτηση *extract_protein_pos()*. Αυτή η συνάρτηση χρησιμοποιεί το *hgvs_p* και από αυτό εξάγει τη θέση του αμινοξικού καταλοίπου που αντιστοιχεί στην παραλλαγή.

Η κύρια συνάρτηση για την επεξεργασία των δεδομένων από την ClinVar είναι η *process_clinvar_data()*. Η συνάρτηση αυτή χρησιμοποιεί *zcat* και *grep* για να κρατήσει μόνο τις καταγραφές που αφορούν ένα συγκεκριμένο γονίδιο, εδώ το TP53, και μόνο μία έκδοση του γονιδιώματος αναφοράς, εδώ GRCh38. Μέσα στον κώδικα υπάρχει η δυνατότητα αλλαγής του γονιδίου, καθώς και της έκδοσης του γονιδιώματος. Λόγω των περιορισμένων πόρων ήταν απαραίτητη η ελάττωση του όγκου των δεδομένων που θα έπρεπε να υποστούν ανάλυση. Για αυτό επιλέχθηκε μόνο ένα γονίδιο. Η επιλογή μόνο μίας έκδοσης του γονιδιώματος αναφοράς, έχει να κάνει τόσο με τη μείωση του

όγκου των δεδομένων, όσο και με το να μην εμφανίζονται διπλότυπα αποτελέσματα, καθώς στο *variant_summary.txt* τα δεδομένα για τις περισσότερες παραλλαγές υπάρχουν σε δύο καταγραφές, μία για κάθε έκδοση του γονιδιώματος, GRCh37 και GRCh38. Μετά από αυτό το φιλτράρισμα, οι καταχωρήσεις του *variant_summary.txt* υπόκεινται σε περαιτέρω επεξεργασία, έτσι ώστε να πάρουν την κατάλληλη μορφή για να μπορούν να ενσωματωθούν στη βάση δεδομένων. Δημιουργείται ένα dataframe με τη χρήση της βιβλιοθήκης *pandas*.

Η συνάρτηση *variant_assortments()* έχει ως σκοπό την εύρεση παρόμοιων παραλλαγών. Δημιουργεί δηλαδή 3 διαφορετικά dataframes, όπου περιέχονται παραλλαγές με ίδιο hgvs_c, hgvs_p ή ίδια αμινοξική θέση, αντίστοιχα. Αυτή η συνάρτηση είναι ιδιαίτερα χρήσιμη για την εφαρμογή των ACMG κριτηρίων, PP5 και BP6. Ακόμη μια χρήσιμη συνάρτηση για αυτού του είδους την εφαρμογή είναι η *split_by_significance()*. Αυτή διαχωρίζει τις παραλλαγές σε dataframes με βάση την κλινική σημασία τους σε 'Pathogenic', 'Benign' ή 'VUS' (variant of uncertain significance). Τα αποτελέσματα αυτών των δύο συναρτήσεων είναι απαραίτητα για τη δημιουργία πινάκων που υποστηρίζουν την ομαδοποίηση των παραλλαγών για την εφαρμογή των κριτηρίων PS1, PM5, PP5 και BP6. Η τελευταία διαδικασία πραγματοποιείται με την εφαρμογή της συνάρτησης *build_acmg_support_tables(df)*.

Παρόλα αυτά, η βασική συνάρτηση για τον έλεγχο της εφαρμογής των ACMG κριτηρίων είναι η *mark_acmg_criteria()*. Η συγκεκριμένη συνάρτηση αξιολογεί κάθε παραλλαγή της ClinVar για το αν μπορεί να χρησιμοποιηθεί ως στοιχείο για την εφαρμογή των ACMG κριτηρίων που έχουν επιλεχθεί. Η *apply_ps1_pm5_pp5_bp6()* είναι η ολοκληρωμένη συνάρτηση και αυτή που χρησιμοποιείται για να απαντήσει στα ερωτήματα του API που αφορούν τόσο νέες όσο και υπάρχουσες παραλλαγές. Στην ουσία, αυτό που κάνει είναι να ελέγξει αν ταιριάζει κάποιο από τα κριτήρια PS1, PM5, PP5 ή BP6 για μία παραλλαγή.

Η τελική συνάρτηση της βάσης δεδομένων είναι η εισαγωγή των δεδομένων στη βάση. Αυτή η διαδικασία πραγματοποιείται με τη χρήση της *insert_to_database()*. Περιέχει τις απαραίτητες διαδικασίες έτσι ώστε τα δεδομένα των παραλλαγών μετά την επεξεργασία που έχουν υποστεί να εισαχθούν σωστά στις κατάλληλες στήλες της βάσης δεδομένων.

Για την εφαρμογή των ACMG κριτηρίων χρησιμοποιούνται δύο στρατηγικές, μέσω ομαδοποίησης ή άμεση προσέγγιση. Για την πρώτη προσέγγιση, υλοποιείται η συνάρτηση *group_based_acmg()*, η οποία ελέγχει μόνο τα κριτήρια PS1 και PM5 για μία παραλλαγή. Πιο συγκεκριμένα, βασίζεται στο αν υπάρχουν παραλλαγές με ίδια αμινοξική θέση, ίδια αλλαγή καταλοίπου ή ίδια αλλαγή του DNA με άλλη κλινική σημασία. Χρησιμοποιεί τις ομαδοποιήσεις που δημιουργήθηκαν σε προηγούμενη συνάρτηση, *build_acmg_support_tables()*.

Για την ομαδοποίηση των παραλλαγών με βάση την κλινική τους σημασία, χρησιμοποιείται η *split_by_significance()*. Με τη χρήση αυτής επιστρέφονται όλες οι παραλλαγές που ανήκουν στις εξής τρεις κατηγορίες κλινικής σημασίας: Pathogenic, Benign και VUS (Uncertain significance).

Επιπλέον βήμα για την κανονικοποίηση της κλινικής σημασίας είναι η μετατροπή σε μικρά γράμματα και συντομογραφίες των όρων που χρησιμοποιούνται για την απόδοση της κλινικής σημασίας των παραλλαγών, έτσι ώστε να είναι πιο εύκολη η αναγνώριση λέξεων κλειδιών και να γίνει αντιστοίχιση με τον ήδη υπάρχον κώδικα. Όλη αυτή η διαδικασία συγκεντρώνεται και πραγματοποιείται μέσα από τη *simplify_clinical_significance()*.

Στον κώδικα υπάρχει η δυνατότητα υπολογισμού ενός score για τις αντικρουόμενες ερμηνείες (conflicting interpretations) μέσω της *compute_conflictinginterpretations()*. Η συνάρτηση αυτή ελέγχει αν μία παραλλαγή, με βάση το Variation ID της, έχει αντικρουόμενες ερμηνείες και την εισάγει σε ένα λεξικό (conflict_dict). Στην ουσία, βλέπει αν στο συγκεκριμένο Variation ID αντιστοιχούν πάνω από μία διαφορετική κλινική σημασία. Με τη βοήθεια της *convert_pipe_string_to_list()*, μετατρέπει τα παραπάνω αποτελέσματα, τα οποία μπορεί να διαχωρίζονται με τη χρήση pipes (|), σε λίστα της οποίας οι καταχωρίσεις διαχωρίζονται με κόμματα (,).

Για την εφαρμογή των ACMG 2015 PP5 και BP6 κριτηρίων, θα χρειαστεί να οριστεί ποιες καταχωρίσεις της ClinVar θεωρούνται αξιόπιστες για να υποστηρίξουν αυτή την αξιολόγηση. Αυτό υλοποιείται μέσω της συνάρτησης *get_reliable_variation_ids_from_variant_summary()*. Αυθαίρετα, θεωρήθηκε ότι μπορούν να χρησιμοποιηθούν για αυτό τον σκοπό, οι παραλλαγές που έχουν ως Review Status 'Reviewed by expert panel', αλλά και όσες παραλλαγές έχουν από τρεις και πάνω καταχωρήσεις στην ClinVar με 2 ή 3 στο Submitter Categories και χωρίς να

υπάρχουν αντιθέσεις. Η στήλη SubmitterCategories του αρχείου variant_summary.txt της ClinVar περιέχει την προέλευση των καταχωρήσεων με συγκεκριμένους αριθμητικούς κωδικούς. Το 1 αντιστοιχεί σε καταχωρήσεις που προέρχονται από εξωτερικές πηγές, όπως άλλες βάσεις δεδομένων, το 2 απευθείας από υποβάλλοντες, όπως από εργαστήρια, όχι από άλλες εξωτερικές πηγές, το 3 τόσο από άλλες εξωτερικές πηγές όσο και από καταχωρήσεις και το 4 αντιστοιχεί στο γεγονός ότι δεν είναι διαθέσιμος ο υποβάλλον ή δεν έχουν καταχωρηθεί δεδομένα. Οι κωδικοί 2 και 3 θεωρήθηκε πως ταιριάζουν καλύτερα με την περιγραφή των κριτηρίων PP5 και BP6, για αυτό και επιλέχθηκαν ως προϋπόθεση.

Τελική συνάρτηση της βάσης δεδομένων είναι η *main()*. Περιέχει όλες τις εντολές για να δημιουργηθεί και να τρέξει η βάση, καθώς και σε ποια σημεία θα πρέπει να εφαρμοστούν όλες οι παραπάνω συναρτήσεις. Αποτελεί, στην ουσία, τον κύριο οδηγό της βάσης δεδομένων. Ακόμη περιέχει και block *try/except/finally*, για να εξασφαλίσει ότι η βάση θα τρέξει σωστά και να εμφανίσει τυχόν σφάλματα.

Από την άλλη πλευρά, έχει δημιουργηθεί και ένα REST API, το οποίο μεσολαβεί ανάμεσα στη βάση δεδομένων και τον χρήστη. Με αυτό τον τρόπο είναι πιο εύκολη η χρήση της βάσης και η δημιουργία ερωτημάτων από χρήστες, οι οποίοι μπορεί να μην είναι τόσο εξοικειωμένοι με τα εργαλεία της βιοπληροφορικής και τις ιδιαιτερότητές τους.

Για την κατασκευή του API χρησιμοποιήθηκε το FastAPI, το οποίο βασίζεται σε Python. Οι βιβλιοθήκες που ήταν απαραίτητες για την περάτωση όλων των διεργασιών ήταν οι: *fastapi*, *typing*, *psycpg2*, *pandas*, *json*, *collections*, *new2* (script της βάσης δεδομένων) και *re*.

Αρχικά, για την καλή λειτουργία του API, θα πρέπει να οριστούν οι κατάλληλες ρυθμίσεις σύνδεσης με τη βάση δεδομένων. Το REST API θα πρέπει να μπορεί να επικοινωνεί και να αντλεί πληροφορίες από τη βάση δεδομένων.

Το API διαθέτει πολλαπλά queries, τα οποία δίνουν μια ευελιξία στη χρήση της βάσης δεδομένων. Με αυτό τον τρόπο η εφαρμογή αποκτά νέες δυνατότητες, καθώς επίσης δίνεται η ευκαιρία για επιπλέον εμπλουτισμό των δυνατοτήτων που μπορεί να έχει αυτό το project.

Ένα από τα βασικά queries που διαθέτει και το πρώτο που εκτελείται είναι το *health_check()*. Το συγκεκριμένο ελέγχει κατά πόσο επιτεύχθηκε σύνδεση του API με τη βάση δεδομένων. Επαληθεύει, δηλαδή, ότι η βάση είναι έτοιμη να δεχτεί ερωτήματα μέσω του API.

Το *user_classify_variant()* είναι το query, το οποίο πραγματοποιεί τη βασική λειτουργία αυτού του project. Δέχεται ως είσοδο το όνομα του γονιδίου και το HGVS_c και ενδεχομένως και το HGVS_p της παραλλαγής, αν δοθεί από τον χρήστη και επιστρέφει τις βασικές πληροφορίες που υπάρχουν για αυτή την παραλλαγή στη βάση δεδομένων, καθώς και ελέγχει αν ισχύει κάποιο από τα ACMG κριτήρια. Αν πρόκειται για καινούρια παραλλαγή, για την οποία δεν υπάρχει καμία καταγραφή στη βάση, τότε ελέγχει για τον αν ισχύουν τα PS1 ή PM5 κριτήρια.

Το *calculate_pp5_bp6_from_summary()* ελέγχει για μία παραλλαγή πόσες καταχωρήσεις με διαφορετική κλινική σημασία υπάρχουν. Με αυτό τον τρόπο επιβεβαιώνει την ισχύ των PP5 ή BP6 αντίστοιχα, καθώς βλέπει αν υπάρχουν αντικρουόμενες ερμηνείες σχετικά με την κλινική σημασία της παραλλαγής.

Η *get_acmg_criteria()* χρειάζεται το όνομα του γονιδίου και προαιρετικά το HGVS_c και το HGVS_p της παραλλαγής. Στην πρώτη περίπτωση, όπου δίνεται μόνο το όνομα του γονιδίου, ελέγχει αν στην βάση δεδομένων υπάρχουν παραλλαγές για το συγκεκριμένο γονίδιο. Στην περίπτωση, όμως, που δίνεται ακριβώς το πλήρες όνομα της παραλλαγής, τότε εφαρμόζει τη συνάρτηση που υπάρχει στη βάση δεδομένων, *apply_ps1_pm5_pp5_bp6()*. Έτσι, ελέγχει αν εφαρμόζεται κάποιο από τα τέσσερα κριτήρια που μελετώνται για τη συγκεκριμένη παραλλαγή.

Ένα επιπλέον query του API αποτελεί το *variants_by_genomic_range()*. Εδώ, η αναζήτηση για παραλλαγές γίνεται με βάση τις γονιδιωματικές συντεταγμένες που δίνει ο χρήστης. Σε αυτή την αναζήτηση είναι σημαντικό να ληφθεί υπ' όψη η έκδοση του γονιδιώματος αναφοράς που χρησιμοποιείται (reference genome assembly). Με παρόμοιο τρόπο λειτουργεί και το query *get_variants_by_protein_pos()*, μόνο που εδώ το εύρος αναζήτησης που ορίζει ο χρήστης είναι με βάση τη θέση του αμινοξικού καταλοίπου στην πρωτεΐνη.

Ακόμα μία λειτουργία του API είναι η *get_variant_counts()*. Με αυτή τη λειτουργία πραγματοποιείται αναζήτηση στη βάση δεδομένων για ένα γονίδιο. Η αναζήτηση αυτή μπορεί να γίνει πιο συγκεκριμένη με την προσθήκη επιπλέον φίλτρων, όπως με βάση

τη συνέπεια της παραλλαγής (π.χ. παρανοηματική (missense)), την κλινική σημασία (π.χ. παθογόνος), την αρχή και το τέλος, δηλαδή το εύρος αμινοξικών καταλοίπων ή την ακριβή θέση του καταλοίπου στην πρωτεΐνη.

Υπάρχουν διαθέσιμα queries για την αναζήτηση πιο γενικών πληροφοριών, όπως το *summary()*, το οποίο τυπώνει τις παραλλαγές του γονιδίου που έχουν την μοριακή συνέπεια της αναζήτησης. Παρομοίως, η *significance_summary()* τυπώνει τις παραλλαγές του γονιδίου με βάση την κλινική σημασία τους. Με τη χρήση αυτών δίνεται μια πιο γενική εικόνα του τι επικρατεί στη βάση δεδομένων.

Στο πλαίσιο της γενικής εικόνας της βάσης δεδομένων ανήκει και η *variant_counts()*. Αυτή πραγματοποιεί αναζήτηση με βάση το όνομα του γονιδίου και την κλινική σημασία και μετράει πόσες παραλλαγές ικανοποιούνται. Έτσι, παίρνουμε μια γενική εικόνα για το τι είδους παραλλαγές εντοπίζονται σε αυτό το γονίδιο.

Το API δίνει, επίσης, τη δυνατότητα στον χρήστη να δει μια επισκόπηση της βάσης δεδομένων. Με την *available_genes()* εμφανίζονται όλα τα γονίδια που υπάρχουν καταχωρημένα στη βάση δεδομένων, ενώ με την *available_consequences()* εμφανίζονται όλοι οι τύποι μοριακών συνεπειών για τους οποίους υπάρχουν καταγραφές στη βάση δεδομένων.

Τέλος, η *search_variants()* δεν ξεφεύγει από τη λογική των προηγούμενων queries. Πραγματοποιεί αναζήτηση παραλλαγών με βάση το όνομα του γονιδίου, τη μοριακή συνέπεια, την κλινική συνέπεια ή τη θέση του αμινοξικού καταλοίπου στην πρωτεΐνη.

Συμπεράσματα – Συζήτηση

Ο παραπάνω κώδικας δημιουργεί μία βάση δεδομένων και κατ' επέκταση ένα API με σκοπό την έρευνα παραλλαγών που έχουν καταγραφεί. Πιο συγκεκριμένα, μπορεί να υποστηρίξει αναζητήσεις σε βάθος με τη χρήση πολλαπλών φίλτρων, όπως με βάση το γονίδιο, την αλλαγή σε επίπεδο DNA (HGVS_c) και πρωτεΐνης (HGVS_p) και εύρους γονιδιωματικών περιοχών. Επίσης, παρέχει βοηθητικά εργαλεία που δίνουν μια γενική εικόνα σχετικά με την αναζήτηση του χρήστη. Αυτά περιλαμβάνουν *counts* και *summaries*, τα οποία είναι ενσωματωμένα στα queries του API. Η κύρια λειτουργία αυτού του κώδικα, όμως, αποτελεί ο έλεγχος της εφαρμογής των ACMG κριτηρίων για την υποβοήθηση στην ερμηνεία των παραλλαγών.

Ο τρόπος με τον οποίο είναι δομημένος ο κώδικας ακολουθεί την νοοτροπία της επέκτασης. Ο κώδικας είναι δομημένος σε τμήματα (blocks). Έτσι, είναι πιο εύκολη η διόρθωση τυχόν προβλημάτων, καθώς και η ενσωμάτωση νέων λειτουργιών, χωρίς να χρειάζεται να αλλάξει όλο το script. Ακόμη, διαθέτει *try/except/finally* blocks, τα οποία συμβάλλουν στην ομαλή λειτουργία του κώδικα και στην αποφυγή της λειτουργίας του κώδικα, ενώ έχει εντοπίσει λάθος.

Σε αυτό το στάδιο, ίσως να υπάρχουν κάποιες διορθώσεις ή λεπτομέρειες που θα πρέπει να αποσαφηνιστούν για την καλύτερη λειτουργία και την επίτευξη μεγαλύτερης ακρίβειας των αποτελεσμάτων της αναζήτησης. Σε αυτά, θα μπορούσε να συμπεριληφθεί ένα φιλτράρισμα για τις παραλλαγές που μετατρέπονται σε κωδικόνιο λήξης (Ter), έτσι ώστε να μη συμπεριλαμβάνονται κατά τη διαδικασία ελέγχου των κριτηρίων. Για την εφαρμογή των κριτηρίων PP5 και BP6, θα πρέπει να πραγματοποιηθούν και άλλες προσαρμογές, για να είναι πιο στοχευμένος και αυστηρός ο έλεγχος. Δεδομένου της φύσης αυτών των κριτηρίων, τα οποία ελέγχουν τι υπάρχει στη βιβλιογραφία σχετικά με τις παραλλαγές που ερευνώνται, θα πρέπει να κανονικοποιηθεί ένας τρόπος αξιολόγησης για το τι αξίζει να συμπεριληφθεί και να επηρεάσει το αποτέλεσμα της εφαρμογής αυτών των κριτηρίων. Μια προσέγγιση που προτάθηκε ήταν η συμπερίληψη της στήλης *Guidelines* του *variant_summary.txt* της ClinVar. Σε αυτή τη στήλη αναγράφεται αν έχουν εφαρμοστεί τα ACMG κριτήρια και ποιων χρονολογιών. Επομένως, αντί να εφαρμοστεί η μέθοδος που ακολουθήσαμε, η οποία είναι περισσότερο ποσοτική, καθώς βασίζεται στον αριθμό των καταχωρήσεων που υπάρχουν για τη συγκεκριμένη παραλλαγή και στο ότι οι καταχωρήσεις ανήκουν στις κατηγορίες 2 ή 3 της στήλης *SubmitterCategories* του *variant_summary.txt* της ClinVar, θα μπορούσαμε να έχουμε πιο άμεσα και ποιοτικά αποτελέσματα, αν χρησιμοποιήσουμε στη θέση αυτής της συνάρτησης μία συνάρτηση που εκμεταλλεύεται τη στήλη *Guidelines*.

Ο κώδικας μπορεί να έχει επιπλέον προεκτάσεις στο μέλλον, οι οποίες θα του προσφέρουν νέες ιδιότητες και θα τον κάνουν πιο λειτουργικό. Σε πρώτο στάδιο, θα ήταν σημαντική η προέκτασή του ώστε να περιλαμβάνει παραπάνω του ενός γονίδια. Για την πιλοτική εφαρμογή του κώδικα, χρησιμοποιήθηκαν οι παραλλαγές ενός μόνο γονιδίου και πιο συγκεκριμένα του TP53. Συνεπώς, επόμενο βήμα είναι η ενσωμάτωση περισσότερων γονιδίων στη βάση δεδομένων.

Η βάση δεδομένων, προς το παρόν, περιορίζεται σε έναν μόνο πίνακα. Η ενσωμάτωση επιπλέον πινάκων στη βάση, θα την εμπλουτίσουν με πληροφορίες και θα της δώσουν τη δυνατότητα για νέες λειτουργίες και την εισαγωγή νέων ερωτημάτων. Σε αυτά τα πλαίσια, θα μπορούσε να ενσωματωθεί και το αρχείο *submission_summary.txt* της ClinVar. Αυτό το αρχείο μπορεί να διαθέσει επιπλέον σημαντικές πληροφορίες για τις καταχωρήσεις των παραλλαγών. Μπορεί να βοηθήσει σημαντικά στον χειρισμό των αντικρουόμενων ερμηνειών (conflicting interpretations) της κλινικής σημασίας, για τις οποίες δεν υπάρχει κάποια συγκεκριμένη οδηγία.

Για την επιβεβαίωση της εγκυρότητας των στοιχείων, θα μπορούσε να προστεθεί η δυνατότητα σύνδεσης με άλλες βάσεις δεδομένων. Με αυτόν τον τρόπο, θα μπορεί να πραγματοποιείται διασταύρωση των πληροφοριών και τα αποτελέσματα να γίνονται πιο αξιόπιστα. Ακόμη μία προσθήκη θα μπορούσε να είναι η παράθεση του αντίστοιχου URL της ClinVar για την παραλλαγή που εμφανίζεται στα αποτελέσματα της αναζήτησης.

Όσον αφορά την εφαρμογή των ACMG κριτηρίων, για αυτά θα μπορούσε να δημιουργηθούν ξεχωριστά blocks για τον έλεγχο του καθενός. Αυτό επιτρέπει την προσθήκη επιπλέον κριτηρίων, με αποτέλεσμα την διεύρυνση των δυνατοτήτων και της χρησιμότητας αυτής της εφαρμογής. Για παράδειγμα, εφόσον υπάρχει ήδη η δυνατότητα αναζήτησης εύρους γονιδιωματικών συντεταγμένων, θα μπορούσε να γίνεται έλεγχος και για την εφαρμογή του PM1 κριτηρίου, το οποίο αναφέρεται στα hotspots.

Κλείνοντας, η δημιουργία ενός γραφικού περιβάλλοντος (graphic interface) που θα αλληλεπιδρά με τον χρήστη, θα κάνει τη βάση ακόμα πιο προσιτή και εύχρηστη. Στην ουσία, η δημιουργία μιας ιστοσελίδας θα μπορούσε να θεωρηθεί το τελικό βήμα αυτής της εφαρμογής.

Βιβλιογραφία

Richards, S., Aziz, N., Bale, S., Bick, D., Das, S., Gastier-Foster, J., Grody, W. W., Hegde, M., Lyon, E., Spector, E., Voelkerding, K., Rehm, H. L., & ACMG Laboratory Quality Assurance Committee (2015). Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of

Medical Genetics and Genomics and the Association for Molecular Pathology. *Genetics in medicine : official journal of the American College of Medical Genetics*, 17(5), 405–424. <https://doi.org/10.1038/gim.2015.30>

Tornesello M. L. (2025). TP53 mutations in cancer: Molecular features and therapeutic opportunities (Review). *International journal of molecular medicine*, 55(1), 7. <https://doi.org/10.3892/ijmm.2024.5448>

Marei, H.E., Althani, A., Afifi, N. *et al.* p53 signaling in cancer progression and therapy. *Cancer Cell Int* 21, 703 (2021). <https://doi.org/10.1186/s12935-021-02396-8>

Chen, X., Zhang, T., Su, W. *et al.* Mutant p53 in cancer: from molecular mechanism to therapeutic modulation. *Cell Death Dis* 13, 974 (2022). <https://doi.org/10.1038/s41419-022-05408-1>

Li, Marilyn M. *et al.* Standards and Guidelines for the Interpretation and Reporting of Sequence Variants in Cancer. *The Journal of Molecular Diagnostics*, Volume 19, Issue 1, 4 – 23

Cortés-Ciriano, I., Gulhan, D.C., Lee, J.JK. *et al.* Computational analysis of cancer genome sequencing data. *Nat Rev Genet* 23, 298–314 (2022). <https://doi.org/10.1038/s41576-021-00431-y>